

INFORME EJECUTIVO: ANÁLISIS DE COSTOS Y FACTURACIÓN CLÍNICA

Nombre y Apellido: Juan Montero

Institución: ITSE (Instituto Técnico Superior Especializado)

Materia: Minería de Datos 1

1. Contexto y Objetivo

El presente análisis se desarrolló sobre el dataset de facturación de la clínica médica con el objetivo de identificar cuáles son los factores demográficos y de salud que tienen mayor impacto en los costos económicos (charges) de los pacientes. El propósito es generar evidencia sólida y justificada que permita optimizar la gestión de riesgo financiero en salud, garantizando la trazabilidad y reproducibilidad de todo el proceso.

2. Dataset y Calidad Inicial

El conjunto de datos original contenía 1.363 registros y 7 variables. Durante la fase de **Perfilado de Datos**, detecté los siguientes problemas de calidad:

- **Valores faltantes:** 102 registros nulos en la variable edad (age) y 50 en el índice de masa corporal (bmi).
- **Inconsistencias de texto:** Valores mezclados como 'No' y 'no' en la columna smoker, y la sigla 'SE' en lugar de 'southeast' en la columna region.

3. Decisiones de Limpieza y Preparación (ETL)

Para solucionar estos problemas sin perder información valiosa, apliqué las siguientes transformaciones justificadas:

1. **Estandarización:** Convertí todas las cadenas de texto a minúsculas y unifiqué las siglas regionales.
2. **Imputación:** Rellené los valores nulos de age y bmi utilizando la **mediana** de cada columna, evitando sesgar la distribución con promedios atípicos.
3. **Remoción de duplicados:** Se eliminaron los registros físicos repetidos para asegurar la unicidad.

La retención final del dataset quedó registrada en el archivo obligatorio de auditoría:

Paso	Descripción	Filas	Nulos	Retención (%)
1	Estandarización de categorías, imputación por mediana y remoción de duplicados	1351	0	99.12%

4. Hallazgos del Análisis Exploratorio (EDA)

A través de las visualizaciones del análisis exploratorio, extraje las siguientes conclusiones clave:

- **Análisis Univariado:** Los costos médicos muestran una distribución con un fuerte sesgo a la derecha; la gran mayoría de los pacientes genera gastos bajos, pero una minoría selecta se extiende en una cola larga de costos extremos.
- **Análisis Bivariado:** El tabaquismo demostró ser la variable individual con mayor impacto. La mediana de gastos de los fumadores supera los \$35.000, frente a los menos de \$10,000 de los no fumadores.
- **Análisis Multivariado (Hallazgo Crítico):** Se descubrió un efecto de sinergia no lineal. En los pacientes no fumadores, el incremento del IMC no altera los costos de forma drástica. Sin embargo, en los fumadores, cruzar la barrera de **IMC = 30 (obesidad)** dispara los costos médicos de manera exponencial hasta alcanzar los \$60.000.

5. Reducción de Dimensionalidad (PCA)

Dado que los montos de la variable charges distorsionaban las distancias debido a su escala, apliqué una normalización estandarizada (StandardScaler) antes de procesar el **Análisis de Componentes Principales (PCA)**.

Los resultados matemáticos indican que las **primeras dos componentes principales logran explicar más del 80% de la varianza total** del dataset. Al proyectar a los pacientes en este nuevo espacio reducido, se observó una separación perfecta y nítida entre los grupos de riesgo (fumadores con alto IMC vs. no fumadores), validando la estructura del análisis.

6. Conclusiones y Limitaciones

- **Conclusión:** Los factores demográficos aislados como la región no determinan el costo médico. El verdadero riesgo financiero de la clínica está concentrado en la interacción de dos factores modificables: la obesidad combinada con el hábito de fumar.
- **Limitaciones:** El alcance de este informe se encuentra condicionado por la necesidad de haber imputado datos faltantes mediante supuestos estadísticos (mediana) y por la ausencia de variables de antecedentes clínicos preexistentes en el set de datos original.